



뉴스 데이터를 활용한
투자 예측 전문가의 매매 종목 알림
서비스



부문 : 빅데이터
팀명 : Chat Finance
팀원 : 김재훈, 문성원, 박민영

분석 배경

우선 M-STOCK 애플리케이션에 적용할 수 있는 서비스를 개발하는 것이기 때문에, M-STOCK에 존재하는 서비스들을 확인해 보았다. '종목의 발견', '쉽게 보는 리서치', '이번 주 금융상품' 등 수많은 서비스들이 있었지만, 주식 자체를 처음 하는 신규 고객들에겐 사실 이조차도 어렵다. 부산대학교 이윤정, 우균 연구원의 논문을 인용하자면, 증권 시장이 발달함에 따라 직접 주식을 매매하는 개인들도 점차 증가하고 있고, 일반적으로 개인 투자자들은 기관 투자자나 외국인 투자자에 비해 정보력, 기업분석 기술 등이 부족해 변화가 많은 주식 시장의 흐름을 파악하거나 투자종목을 선택하는 것은 어려운 일이라고 한다.¹⁾ 이를 요약하면, 주식을 어렵게 생각하게 되는 원인은 아래와 같다.

- 1) 투자 지식의 부족
- 2) 방대한 정보량

이 중 투자 지식은 사실 유튜브, 책등 이미 수많은 정보가 존재한다. 우리가 눈여겨본 원인은 방대한 정보량이다. 주식 시장의 특성상 빠르게 변동하고 업데이트되는 정보들이 많아서, 정보의 과부하가 발생한다. 특히 인터넷과 소셜 미디어의 보급으로 인해 뉴스, 전문가 의견, 투자자들의 다양한 조언들이 쏟아지는데, 이들을 제대로 해석하고 활용하는 것은 어려운 일이다.

27일 한국언론진흥재단에 따르면, 주식 뉴스 이용자 1000명을 대상으로 설문조사를 한 결과 61.9%가 주식 관련 언론 보도가 주식투자에 도움이 된다고 답했고, 특히 72.2%가 '증권사 사이트/앱'을 가장 신뢰하는 것을 밝혀졌다.²⁾ 이에 따라 현재 M-STOCK에서 제공하고 있는 뉴스 페이지가 고객 대부분에게 많은 관심거리임은 당연하다. 하지만, 이러한 뉴스가 어떤 종목에 어떤 영향을 미치는지 파악하기엔 신규 고객들에겐 어렵다.

다시 말해, 정보 네트워크가 없는 신규 고객이 기사를 보고 종목을 매수, 매도하는 것은 서울에서 김서방 찾기와 마찬가지로 어렵다. 또한, 바로바로 뉴스를 확인하더라도 그 정보가 특정 종목에 이미 영향을 준 지 오래됐을 가능성이 크며, 정보를 기사가 아닌 특정 네트워크로 수집하는 전문 투자자들에 비하면, 크게 뒤쳐진 경우가 다반사이다.

신한 금융투자 투자분석부 정의석 부장은 다음과 같이 인터뷰했다. "공시되지 않은 정보를 활용한 내부자 거래는 명백한 불법이지만 대부분 기업에서 정보가 미리 흘러나온다" 또한 "정보력이 떨어지는 개인 투자자들은 뒤늦게 뛰어들어 상투를 잡거나 잘못된 정보에 현혹되기 쉽다"라고 언급했다. 위의 문제에 대한 전문가의 의견도 다르지 않았다.

심지어 주식을 오랫동안 해온 기존 고객들조차 어떤 뉴스를 보고 어떤 종목이 오르거나 내려갈지 추측하는 것은 매우 어려우며, 거짓 뉴스도 많아 방대하고 긴 텍스트로 구성된 기사를 읽는 시간조차 버거운 현 사회이다.

물론 현재 M-STOCK에는 뉴스를 긍정, 부정, 중립으로 분류하여 보여주는 서비스가 존재한다. 이는 뉴스 내용을 파악하기엔 큰 도움이 될 수 있으나, 신규 고객에게는 뉴스를 보고 스스로 판단하는 것조차 매우 두려운 일이다.

그렇기에 우리는 두 가지 서비스로부터 힌트를 얻어 다음과 같은 서비스 아이디어를 얻었다.

- 1) 뉴스의 긍정, 부정, 중립 분류 서비스
- 2) 지역 내 인기 종목 알림 서비스

1) 이윤정 / 우균, 「주식 포트폴리오 추천을 위한 주식 시장 네트워크 분석」, 부산대학교, 2013

2) 김슬기, 「주식 뉴스 이용자 62% "언론보도가 주식투자에 도움 된다"」, 매일경제, 2022


이 유용한 두 서비스를 보고, 뉴스 데이터와 관련 종목, 고객 데이터 이 세 가지를 잘 엮는다면, 지역 내 인기 종목 알람 서비스같이, 뉴스 판단이 어려운 신규 고객에게 길잡이를 해줄 수 있는 서비스를 개발할 수 있지 않을까라는 아이디어를 얻었다.

즉, 우리는 특정 주식 정보를 미리 알고 있는 주식 고수 고객을 찾아, 그 고객의 최근 관심 종목과 위험한 종목을 알려주는 서비스를 개발하고자 한다.

우리는 이를 "홍길동"이라 부르고자 한다.

분석 방향

1) 데이터 활용 및 전처리



주어진 세 가지 데이터를 잘 활용할 필요가 있다.

1.1) 뉴스데이터

우선 뉴스가 뜬 시점으로부터 특정 시간이 지난 후 특정 종목을 매도, 매수하는 고객을 찾는 것을 목표로 하기 때문에, 뉴스 데이터의 감정 분석을 할 필요가 있었다. 뉴스가 긍정적인 뉴스인지, 부정적인 뉴스인지에 따라 고객이 관련 종목을 매도할지, 매수할지를 결정하기 때문이다.

감정 분석을 위해, 뉴스 데이터 전처리를 진행했다.

일단, 12월부터 6월까지의 뉴스 데이터를 하나로 합쳤다. 감정 분석에 필요한 변수는 'TITLE(뉴스 제목)', 'CONTENT(뉴스 내용)', 'IMPORTANCE(뉴스 중요도)', 'ITEM_NAME(뉴스 연관 종목 면)', 'DATE_TIME(뉴스 수신 시각)'이며, 'WRITER', 'SUBCATEGORY', 'TAG_LIST'의 경우, 각각 과도한 데이터 량과 효율성으로 누락시켰으며, 뉴스 제목으로 충분히 감정 분석이 가능할 것이라 판단했다. 따라서 필요한 변수를 제외하고 모두 제거를 한 후 '-' 문자로 이어진 종목명을 분리한 후 'ITEM_NAME_ONLY(종목 번호)'를 추가하였다.

감성 분석 모델의 경우는, 네이버에서 제공하는 CLOVA Sentiment를 활용하려 했었으나, 비용, 시간의 문제로 최대한 흡사하고 성능이 준수한 모델인 KLUE-BERT 모델을 사용했다.

	DATE_TIME	TITLE	IMPORTANCE	CONTENT	NEWS_NUM	ITEM_NAME_ONLY	단축코드
0	20230101	"이미 모든 약재 나왔다"...전문가가 뽑은 내년 돌 업종은?	58.26	[머니투데이 홍순빈 기자] [[2023 중시 전망]국내 중시 주목할 업종]_x000...	1	고려아연	010130
1	20230101	"이미 모든 약재 나왔다"...전문가가 뽑은 내년 돌 업종은?	58.26	[머니투데이 홍순빈 기자] [[2023 중시 전망]국내 중시 주목할 업종]_x000...	1	영풍	000670
2	20230102	CES엔 대기업만 있나?...삼성 C랩 LG NOVA' 특목 뛰는 스타트업 항연	63.81	[머니투데이 한지연 기자] [[CES 2023 개막]_x000D_in_x000D...	2	삼성전자	005930
3	20230102	CES엔 대기업만 있나?...삼성 C랩 LG NOVA' 특목 뛰는 스타트업 항연	63.81	[머니투데이 한지연 기자] [[CES 2023 개막]_x000D_in_x000D...	2	LG전자	066570
4	20230102	CBI "지난해 최대 매출 기대...올해도 기록적인 성장세 전망"	58.19	[머니투데이 김건우 기자] _x000D_in자동차 부품업체 CBI는 지난해 글로벌 ...	3	CBI	013720

1.2) 고객데이터

고객 데이터의 경우 우선 고객을 식별하기 위해 고유 번호를 추가한 뒤 'BUY1(2,3)_ITM(매수 종목 번호)', 'BUY1(2,3)_AMT(매수액)', 'SEL1(2,3)_ITM(매도 종목 번호)', 'SEL1(2,3)_AMT(매도액)'를 이용하여 '날짜', '매수(종목번호)', '매수액', '매도(종목번호)', '매도액'의 열을 만들었다. 이때 날짜 변수는 해당 고객이 종목을 뉴스가 뜨기 전에 샀는지 알기 위함으로 중간 날짜로 하거나 앞 날짜로 할 경우 뉴스가 뜬 후에 샀지만 사기 전에 산 것으로 잘못 분류될 수 있기 때문에 12월부터 3월까지 초순, 중순, 하순의 끝 날짜를 이용했다.

	NUM	DATE	BUY	BUY_MONEY	SELL	SELL_MONEY
24099240	1	20230320	NaN	NaN	218420	2800000.0
26509164	1	20230331	453540	3000000.0	*	6000000.0
9639697	2	20230120	NaN	NaN	009240	5100000.0
12049621	2	20230131	NaN	NaN	005930	1900000.0
14459545	2	20230210	302440	2200000.0	238490	5700000.0
...	...	...	...	...	...	...
12852927	803308	20230131	099430	660000.0	161890	440000.0
15262851	803308	20230210	099430	560000.0	NaN	NaN
17672775	803308	20230220	085370	1000000.0	NaN	NaN
24902547	803308	20230320	099430	680000.0	NaN	NaN
13656235	803308	20230131	NaN	NaN	003490	330000.0

7097413 rows × 6 columns

2) NLP 모델

본래 네이버에서 제공하는 CLOVA Sentiment를 활용하는 것이 목적이며, CLOVA Sentiment를 사용하는 이유는 다음과 같다.

2.1) CLOVA Sentiment

- 1) 빠른 처리 속도: 한국어에 최적화된 방식으로 pre-training을 수행하고 Shallow BERT 적용으로 4배 빠른 처리 속도 제공이 가능한 모델이다.
- 2) 주요 감정 표현 추출: BERT의 Attention 정보를 활용함으로써 문장의 긍정/부정/중립 등의 감정 분석 정보뿐만 아니라 감정 판단의 핵심이 되는 주요 감정 표현을 추출할 수 있다.
- 3) 다양한 도메인에서의 활용성: 쇼핑, 호텔, 맛집, 뉴스, SNS 등 다양한 환경의 도메인을 제공하여 범용적으로 활용할 수 있다.

2.2) CLOVA NSML

- 1) 쉽고 편리한 사용: CLOUD 환경에서 효율적으로 동작하여, 편리한 데이터 관리가 된다.
- 2) 효율적 자원 활용: GPU Clustering 및 Scheduling을 통해 자원을 효율적으로 관리하고 배분한다.
- 3) 모델 성능 최적화: AutoML을 통해 자동으로 파라미터를 튜닝하고 성능을 최적화한다.

위와 같은 이유로 CLOVA Sentiment와 NSML을 사용하는 것이 가장 좋다고 판단했다. 하나, 예선에서는 네이버 CLOVA를 활용하는 것 비용상 어렵기 때문에, 최대한 비슷한 모델인 KLUE-BERT 모델을 활용하였으며, 이 모델은 NAVER, KAIST 등 신뢰성 높은 기업에서 한국어 데이터 부족, 평가 지표의 한계를 극복하기 위한 오픈 프로젝트로 설계되었다.

2.3) KLUE-BERT model

이 모델에선 epoch³⁾ 을 10으로 설정했으며, 정확도는 약 78%이며 시간을 고려해 적절한 epoch을 설정하여 최선의 모델을 구성했다.

이 모델을 학습시킨 데이터는 finance_sentiment_corpus로 감정 분석이 완료된 경제 뉴스 기사 데이터 셋을 활용하였다. 여기엔 '한국 매일 경제 뉴스', '연합뉴스 헤드라인' 등이 포함됐다. 이 모델을 돌리기 전에 중복 값을 없애고 학습 데이터에서 영어로 된 'sentence'열을 제외했고, label 변수의 값을 다음과 같이 변경했다. (중립) 0, 긍정) 1, 부정) 2)

	labels	sentence	kor_sentence
0	neutral	According to Gran, the company has no plans to...	Gran에 따르면, 그 회사는 회사가 성장하고 있는 곳이지만, 모든 생산을 러시아로...
1	neutral	Technopolis plans to develop in stages an area...	테크노폴리스는 컴퓨터 기술과 통신 분야에서 일하는 회사들을 유치하기 위해 10만 평...
2	negative	The international electronic industry company ...	국제 전자산업 회사인 엘코텍은 탈린 공장에서 수십 명의 직원을 해고했으며, 이전의...
3	positive	With the new production plant the company woul...	새로운 생산공장으로 인해 회사는 예상되는 수요 증가를 충족시킬 수 있는 능력을 증가...
4	positive	According to the company's updated strategy fo...	2009-2012년 회사의 업데이트된 전략에 따르면, Basware는 20% - 4...

X_data(입력 데이터)에는 'kor_sentence', y_data(결과 출력 데이터)에는 'label'이 들어가도록 분리했다. train과 test의 비율은 8:2 지정했으며, 학습 데이터가 약 5000개로 많지 않기 때문에, 학습을 최대한으로 끌어올리기 위해서 train을 최대한 크게 잡았다.

BERT 기반 모델링을 하기 위해서, 데이터를 BERT 모델이 인식할 수 있도록 바꿔줘야 한다. 기존의 텍스트 데이터를 'Token', 'Segment', 'Position'값으로 바꿔준다.

각 값이 해주는 역할은 다음과 같다.

'Token': 각 문자열을 최소의 단위로 나누고 인덱스 번호를 부여

'Segment': 문장의 앞뒤 관계를 구분

'Position': 각 단어의 위치 값

샘플이 부족 때문에 학습 안정성을 위해 옵티마이저는 RAdam을 사용하였다. 중립, 긍정, 부정으로 멀티클래스 분류 모델이므로 Sparse Categorical Crossentropy 손실 함수를 사용했다.

이후 test 셋을 돌렸을 때, 분류 정확도는 83.2%, f1-score는 82.9%로 적절한 모델링이 되었다고 판단했다.

3) 모델이 전체 학습 데이터셋을 학습한 횟수

```

predicted_value = sentiment_model_best.predict(test_x)
predicted_label = np.argmax(predicted_value, axis = 1)

cl_report = classification_report(test_y, predicted_label, output_dict = True)
cl_report_df = pd.DataFrame(cl_report).transpose()
cl_report_df = cl_report_df.round(3)
cl_report_df.to_csv("CL_REPORT_FILE")
print(cl_report_df)

```

```


31/31 [=====] - 202s 7s/step

```

	precision	recall	f1-score	support
0	0.847	0.911	0.878	576.000
1	0.775	0.733	0.753	273.000
2	0.891	0.678	0.770	121.000
accuracy	0.832	0.832	0.832	0.832
macro avg	0.838	0.774	0.800	970.000
weighted avg	0.832	0.832	0.829	970.000

이 모델을 활용하여, 전처리된 뉴스 데이터에서 'CONTENT' 뉴스 내용 변수를 가지고 감정 분석하였다.

그 후, 정확하게 분류되었는지 확인하기 위해서 뉴스를 분류했을 때 부정, 긍정에서 가장 많이 나타나는 단어들을 시각화하였다.



위의 Word cloud를 보았을 때, 긍정으로 판단된 뉴스 데이터 셋 Word cloud에서는 "이것부터", "부터 사라", "매수" 등의 단어가 주를 이뤘고, 부정으로 판단된 뉴스 데이터 셋의 Word cloud에서는 "지수 하락을", "매수의", "현재 하락종목은" 등의 단어가 주를 이뤘다. 이를 통해 분류가 적절히 됐다고 확인할 수 있었다.

3) 메인 코드

전처리한 고객 데이터와 뉴스 데이터를 활용하여 뉴스가 보도되기 전에 미리 관련 종목을 구매한 고객을 찾았다. 코드가 돌아가는 시간을 줄이고자 같은 날 보도된 같은 관련 종목의 뉴스를 제거하여 중복을 없앴다. 또한 뉴스가 긍정일 때는 미리 매수한 게 좋은 것이고 부정일 때는 매도한 것이 좋은 것이므로 두 경우를 분리하여 찾고자 뉴스 데이터와 고객 데이터를 각각 긍정과 부정 매수와 매도로 분리하였다. 그 후 12월에서 2월까지의 데이터를 활용해서 투자 예측 전문가를 찾고 3월 데이터로 실제로 그 사람들이 예측을 잘했는지 알기 위해서 train 데이터 셋(12~2월)과 test 데이터 셋(3월)을 분리하였다. 마지막으로 코드에서만 쓰이는 변수인 고객 데이터의 '종목 코드', '고객 고유 번호', '매매한 날짜' 와 '뉴스 데이터의 종목 코드', '뉴스가 보도된 날짜'만을 제외하고 나머지 변수는 전부 제거하였다.

DATE_TIME 단축코드			NUM DATE BUY			
2	2023-01-02	005930	4	2	2023-02-10	302440
3	2023-01-02	066570	9	3	2022-12-10	170030
4	2023-01-02	013720	10	3	2022-12-20	207760
50	2023-01-04	000080	11	3	2022-12-31	419120
71	2023-01-04	039130	12	3	2023-01-10	054920
...	...	...	...	...	...	...
264663	2023-03-07	002920	7097406	803308	2022-12-10	099430
264882	2023-03-15	066900	7097407	803308	2022-12-31	099430
265175	2023-03-24	067570	7097408	803308	2023-01-31	099430
266420	2023-03-22	005440	7097409	803308	2023-02-10	099430
266820	2023-03-02	251370	7097410	803308	2023-02-20	085370
2185 rows × 2 columns			3606273 rows × 3 columns			
고객 데이터			뉴스 데이터			

이후 뉴스가 보도되기 10일 전에 매매한 사람들을 찾았다. 이는 고객 데이터에서 날짜의 가장 늦은 값이 들어가 있기에 최소 하루 전부터 최대 10일 전에 구매한 고객들이다. 적합한 일수를 찾기 위해 5일, 10일, 15일을 해본 결과 “10일” 가장 적합하다고 판단했다. 따라서 뉴스 보도 전 매수한 사람들과 매도한 사람들을 각각 찾은 뒤 이들이 매매한 횟수를 찾았다. 이를 각각의 사람들의 전체 매매 횟수와 비교하여 “60%” 이상의 비율로 매수와 매도를 모두 한 사람들을 투자 예측 전문가로 분류하기로 했다.

우선 정확하게 나왔는지 확인하기 위해서 투자 예측 전문가들이 3월에 구매한 상위 10개의 종목이 3월 이후에 올랐는지, 뉴스는 얼마나 나왔는지를 확인해 보았다. 그 결과 매수에서는 많은 종목이 3월 이후에 주가가 상승했고 매도의 경우도 마찬가지로 3월 이후에 하락하는 추세였다. 하지만 간혹 상승하거나 변화가 없는 경우도 존재했다. 하지만 상위 항목의 경우 달랐다. 매수 2위 종목인 SK하이닉스의 경우 3월부터 조금씩 오른 것은 사실이지만 5월부터 급등했다. 3월과 최고점인 7월을 비교해보면 약 40%가 상승했다. 이를 미리 알고 매수할 수 있었다면 고객들은 큰 이익을 봤을 것이다. 매도의 경우 LB인베스트먼트가 3월에 상장하여 첫날 상장하고 상한가를 찍었다. 하지만 그 이후 계속된 하락세를 보였다. 만약 상장하고 상한가를 찍어 계속해서 가지고 있던 정보가 없던 고객들은 큰 손실을 봤을 것이다.


BUY		SELL	
005930	122	309960	51
000660	51	005930	29
005935	46	247540	22
035420	39	034020	15
247540	39	086520	13
...		...	
215000	1	079810	1
319400	1	300080	1
006220	1	001040	1
267790	1	032620	1
077970	1	002990	1
Name: count, Length: 655, dtype: int64		Name: count, Length: 427, dtype: int64	
매수		매도	



서비스 실현 예상도

주식 정보 습득이 어려운 투자자들을 주 타깃으로 잡은 서비스의 목적에 따라 전문 용어보단, 간단한 형태와 언어로 친근하게 다가갈 수 있도록 제작했다.

뉴스가 보도되기 전 미리 종목을 매매하는 전문가들을 투자 예측 전문가로 선정하여 투자 예측 전문가들이 매매하는 종목을 알려주는 서비스를 제공하는 것이 목표이기 때문에, 예측 전문가를 선정하고 그 선정 이유를 시각화로 고객에게 전달하는 것이 중요하다.



서비스를 통해 투자 예측 전문가들이 현시점 가장 많이 사고파는 종목을 랭크 리스트화해서 보여줄 예정이다. 이때, 우리는 예측 전문가들이 매매한 시점에서 뉴스가 보도되기까지의 기간을 고객이 직접 정하게 함으로써 고객들이 정한 기간에 따라 투자 예측 전문가들이 변한다. 또한 예측 전문가들을 분류하는 정확도 역시 고객들이 직접 설정하게 하여 고객들에게 자신이 가장 적합한 스타일을 설정할 수 있게 할 것이다. 이를 통해 예측 전문가들의 예측률을 아래의 분포도로 보여줌으로써 신뢰도를 높일 것이다. 고객에게 선택권을 주게 되면 자유를 주고, 유동적인 판단이 가능하게 할 것이다.



만약, 보고 싶은 종목을 클릭하게 된다면, 좌측 화면으로 넘어가게 되는데, 상단에 현 예측 전문가들의 몇 퍼센트가 이 종목을 매도, 매수 중인지를 시각화하여 보여주고, 아래에 종목 관련 정보를 보여주는 형식이다.

또한 좌측 화면과 같이 이용자가 원한다면, 알람 서비스를 제공하는 것도 생각했다. 특히 현재 고객이 보유 중인 종목의 경우, 투자 예측 전문가들의 투자 상황에 따라, 실시간으로 정보를 제공해줌으로써, 또는 투자 예측 전문가 중 일정 비율 이상의 사람들이 특정 종목을 매도하면 알람이 가는 서비스를 통해 많은 시간을 할애하지 못하는 신규 고객에게 큰 도움이 될 것으로 예상된다. 또한, 특정 주식의 급등 혹은 급락이 일어나기 전 매매를 통해 높은 수익률의 투자를 유도할 수 있다.

기대효과 및 의의

앞서 말했듯이, 이 서비스는 주식 정보 습득이 어려운 투자자들을 주 타겟으로 잡았다. 그런 의미에서 단순히 투자 수익률이 높거나 자산이 많은 사람들이 매매하는 종목을 추천하는 것이 아니다.

뉴스 정보를 잘 파악하고 정보를 미리 아는 사람들의 종목을 공유함으로써 평소 뉴스를 보고 종목을 매매가 어려웠던 사람들에게 높은 수익을 기대할 수 있게 한다. 다시 말해, 이 서비스를 통해 고객들은 뉴스보다 빠른 정보를 얻을 수 있는 것이다.

사람들이 수익을 내는 기대감보다 잃는 불안감이 더 크다는 사실 때문에, 본 조의 투자 예측 전문가 중 일정 비율 이상의 사람들이 특정 종목을 매도하면 알람이 가는 서비스는 많은 주식 투자자들에게 큰 도움이 될 것으로 예상되고, 심지어 작전세력에 휘말리는 투자자들도 살릴 수 있다는 생각이 든다.

미리 어떤 정보를 알고 매수를 하거나 매도를 하는 사람들을 찾는 이 모델은 사실 매수보다 매도 파트에 좀 더 집중에서 볼 필요가 있다. 매수는 차트가 좋아서 또는 우연히 그 종목이 눈에 띄어서 샀을 가능성이 존재한다. 하지만, 매도는 차트를 보고 또는 우연히 그 종목을 팔 가능성은 매우 적다. 다시 말해, 본 서비스를 이용하는 고객이 보유한 종목 중 투자 예측 전문가들이 매도하는 종목을 알려주는 서비스가 고객들의 큰 손실을 막아 매력적으로 다가올 것이다.

한계

이 서비스엔 뉴스와 고객 데이터를 실시간으로 반영할 수 있다면 뉴스가 뜨기 전에 정보를 미리 제공할 수 있다는 아주 큰 장점이 있다. 하지만 아쉽게도 우리가 보유하고 있는 데이터는 2022년 12월부터 2023년 3월의 데이터로 약 4~7개월 전 데이터이다. 따라서 실시간으로 데이터를 제공받거나 크롤링을 통해 데이터를 수집할 수 있다면 실시간 업데이트를 통해 투자 예측 전문가들이 현 상황에 맞게 변한다. 이를 통해 더욱 빠르고 정확한 정보 제공이 가능할 것으로 예상된다.

본선 진출 시, 방향성

우선 데이터 처리에서 아쉬운 점은 고객 데이터에서 매수액과 매도액 변수를 만들었지만, 이를 이용하지 못한 점이다. 매수액과 매도액을 이용해서 좀 더 정확하게 언제 사고 언제 팔았는지, 얼마나 사고 팔았는지를 가중치로 활용하면 좀 더 정확한 분석이 될 것으로 예상된다.

뉴스 데이터에선 중요도가 실제 주식의 가격에 미치는 중요도와 연관성이 떨어지는 부분에서 데이터의 한계를 느꼈다. 실제 주식의 가격에 영향을 미치는 중요도가 표시된다면, 데이터 분석에 좀 더 효율적으로 뉴스를 사용할 수 있을 것이다. 예를 들어, EDA 중 뉴스 데이터에서 제공된 파일 중 하나를 뽑아 중요도가 높은 나열한 결과, "윤석열 대통령, 인천 국가대표 선수촌 방문 [뉴시스 Pic]" 뉴스가 중요도가 높았다. 다시 말해, 중요도가 높음에도 어떤 종목에 어떤 영향을 미치는지 정확하게 알 수 없는 데이터들이 많았기 때문에, 중요도를 모델에 적용하는 것은 어려웠다.

또한 본 조는 krx 정보 데이터시스템에서 한국 주식의 종목 코드를 다운로드해서 사용하였다. 받은 데이터를 뉴스 데이터의 종목에 합쳐서 종목명을 종목 코드로 대체하였다. 다만, 해외 종목 코드와 다운로드한 데이터에 없는 종목들은 코드로 대체하지 못하였고 이 부분이 아쉬움이 있었다. 처음 데이터의 종목이 종목 코드로 나와 있었으면 더 나은 데이터 분석 결과를 보일 수 있었을 것이라 생각한다.

참고문헌

이윤정 / 우균, 「주식 포트폴리오 추천을 위한 주식 시장 네트워크 분석」, 부산대학교, 2013

김슬기, 「주식 뉴스 이용자 62% "언론보도가 주식투자에 도움 된다」, 매일경제, 2022